

# Chapter 6

## Uncertainty Management

### Tujuan Instruksional Khusus

- Mahasiswa memahami pendekatan Bayesian sebagai dasar interpretasi fakta yang memiliki derajat ketidakpastian tertentu.
- Mahasiswa mampu membuat interpretasi fakta dengan menggunakan metoda certainty factor.
- Mahasiswa mampu mendefinisikan dan menyelesaikan (menarik kesimpulan) permasalahan yang mengandung fakta dengan derajat ketidakpastian tertentu.

### 6.1 Pendahuluan

- Dalam pembicaraan sistem intelligent, dalam banyak hal kita berhadapan dengan data yang bersifat ambigu, samar dan tidak pasti. Sebagai contoh, pada sebuah fakta: **Angin bertiup kencang**, terkandung ketidakpastian terhadap berapa tingkat kekencangan dari tiupan angin. Dalam bahasa sehari-hari, kita sering menjumpai

fakta-fakta yang samar/ambigu/tidak pasti seperti pada contoh di atas.

Note:

- Karena itu dalam hal representasi knowledge dibutuhkan juga suatu cara agar derajat ketidakpastian dari sebuah fakta dapat terwakili dengan baik. Representasi pengetahuan semacam inilah yang akan dibahas dalam *uncertainty management*.
- Setidaknya terdapat tiga issue yang harus diselesaikan dalam pembahasan *uncertainty management*, yaitu:
  1. Bagaimana merepresentasikan data yang tidak pasti (uncertain data)?
  2. Bagaimana mengkombinasikan dua atau lebih data yang tidak pasti?
  3. Bagaimana mengambil kesimpulan (inferensi) menggunakan data yang tidak pasti?

## 6.2 Pendekatan Bayesian

Note:

- Bayes' Rule merupakan teknik tertua dan paling baik untuk menggambarkan ketidakpastian. Bayes' Rule dibangun berdasarkan teori probabilitas klasik.
- Misalkan  $x_i$  adalah beberapa *event*, koleksi dari semua event yang disebut *sample space* didefinisikan sebagai himpunan  $X$  (huruf kapital), yang mana:

$$X = \{x_1, x_2, \dots, x_n\}$$

- Probabilitas dari event  $x_i$  terjadi dinotasikan sebagai  $p(x)$ .

- Setiap fungsi probabilitas,  $p$ , harus memenuhi tiga kondisi di bawah ini:
  1. Probabilitas dari sembarang event  $x_i$  adalah positif. Probabilitas sebuah event mungkin 0 (event tidak akan terjadi) atau mungkin 1 (event pasti terjadi) atau mungkin sembarang nilai antara 0 dan 1.
  2. Jumlah total probabilitas untuk seluruh sample space adalah satu (1).
  3. Jika satu set event  $x_i, x_2, \dots, x_k$  adalah *mutually exclusive*, maka probabilitas bahwa paling tidak satu dari event tersebut terjadi adalah jumlah dari semua probabilitas dari masing-masing elemen.
- Misalkan kita memiliki dua buah event  $x$  dan  $y$  dari sebuah sample space, kemungkinan/probabilitas bahwa event  $y$  terjadi jika event  $x$  terjadi, disebut sebagai *conditional probability* dan ditulis sebagai  $p(y|x)$ . Probabilitas keduanya terjadi disebut sebagai *joint probability* dan dinotasikan sebagai  $p(x \wedge y)$ . Menurut Bayes' rule, conditional probability didefinisikan sebagai:

$$p(y|x) = \frac{p(x|y) * p(y)}{p(x)} \quad (6.1)$$

dalam bentuk yang lain, Bayes' rule juga dapat ditulis sebagai:

$$p(y|x) = \frac{p(x|y) * p(y)}{p(x|y) * p(y) + p(x|\sim y) * p(\sim y)}. \quad (6.2)$$

### 6.2.1 Bayes' Rule dan Sistem Berbasis Pengetahuan

*Note:*

Seperti pada pembahasan dalam Bab 3, sistem berbasis pengetahuan dapat direpresentasikan dalam format IF-THEN dengan:

```
IF    X adalah benar
THEN Y dapat disimpulkan dengan probabilitas p
```

Artinya, apabila hasil observasi kita menunjukkan bahwa  $X$  adalah benar, maka dapat disimpulkan bahwa  $Y$  ada dengan probabilitas tertentu. Sebagai contoh:

```
IF    Seseorang sedang marah
THEN Seseorang akan meninggalkan rumah (0.75)
```

Akan tetapi jika observasi dilakukan terhadap  $Y$  tanpa mengetahui apapun yang terjadi dengan  $X$ , kesimpulan apa yang dapat ditarik? Bayes' rule mendefinisikan bagaimana kita dapat menurunkan probabilitas dari  $X$ .  $Y$  seringkali juga disebut sebagai evidence (disimbolkan dengan  $E$ ) dan  $X$  disebut sebagai hypothesis (disimbolkan dengan  $H$ ), maka persamaan Bayes' rule menjadi:

$$p(H|E) = \frac{p(E|H) * p(H)}{p(E)} \quad (6.3)$$

atau

$$p(H|E) = \frac{p(E|H) * p(H)}{p(E|H) * p(H) + p(x|\sim H) * p(\sim H)}. \quad (6.4)$$

Sekarang marilah kita hitung kemungkinan bahwa Joko sedang marah jika diketahui bahwa ia meninggalkan rumah.

- Persamaan 6.3 menunjukkan bahwa probabilitas bahwa Joko sedang marah jika diketahui bahwa ia sedang meninggalkan rumah adalah:

perbandingan antara probabilitas bahwa Joko marah dan meninggalkan rumah dengan probabilitas bahwa ia meninggalkan rumah.

- Probabilitas bahwa Joko meninggalkan rumah adalah jumlah antara conditional probability bahwa ia meninggalkan rumah jika ia marah dan conditional probability bahwa ia meninggalkan rumah jika ia tidak marah. Dengan kalimat lain item ini berarti probabilitas bahwa ia meninggalkan rumah tidak peduli apakah Joko marah atau tidak.

Misalkan diketahui data-data sebagai berikut:

$$\begin{aligned} p(H) &= p(\text{Joko sedang marah}) \\ &= 0.2 \end{aligned}$$

$$\begin{aligned} p(E|H) &= p(\text{Joko meninggalkan rumah}|\text{Joko sedang marah}) \\ &= 0.75 \end{aligned}$$

$$\begin{aligned} p(E|\sim H) &= p(\text{Joko meninggalkan rumah}|\text{Joko tidak sedang marah}) \\ &= 0.2 \end{aligned}$$

maka

$$\begin{aligned} p(E) &= p(\text{Joko meninggalkan rumah}) \\ &= (0.75)(0.2) + (0.2)(0.8) \\ &= 0.31 \end{aligned}$$

dan

$$\begin{aligned} p(H|E) &= p(\text{Joko sedang marah}|\text{Joko meninggalkan rumah}) \\ &= \frac{(0.75) * (0.2)}{(0.31)} \\ &= 0.48387 \end{aligned}$$

Dengan kata lain, probabilitas bahwa Joko sedang marah jika diketahui bahwa ia meninggalkan rumah adalah sekitar 0.5. Dengan cara

yang sama probabilitas bahwa ia sedang marah jika Joko tidak meninggalkan rumah adalah:

$$\begin{aligned} p(H|\sim E) &= \frac{p(\sim E|H) * p(H)}{p(\sim E)} \\ &= \frac{(1 - 0.75) * (0.2)}{(1 - 0.31)} \\ &= 0.07246 \end{aligned}$$

Jadi dengan mengetahui bahwa Joko meninggalkan rumah, meningkatkan probabilitas bahwa ia sedang marah kira-kira 2.5 kali. Sedangkan mengetahui bahwa ia tidak meninggalkan rumah menurunkan probabilitas bahwa ia sedang marah sekitar 3 kali.

### 6.2.2 Propagasi Kepercayaan

*Note:*

Sebagaimana dibicarakan dalam sub-Bab sebelumnya, Bayes' rule hanya mempertimbangkan satu hypothesis dan satu evidence. Sebenarnya Bayes' rule dapat digeneralisasi untuk kasus dimana terdapat  $m$  hypothesis dan  $n$  evidence yang biasanya ditemui dalam kehidupan sehari-hari. Maka persamaan Bayes' rule menjadi:

$$\begin{aligned} p(H_i|E_1E_2 \dots E_n) &= \frac{p(E_1E_2 \dots E_n|H_i) * p(H_i)}{p(E_1E_2 \dots E_n)} \\ &= \frac{p(E_1|H_i) * p(E_2|H_i) * p(E_n|H_i) * p(H_i)}{\sum_{k=1}^m p(E_1|H_k) * p(E_2|H_k) * \dots * p(E_n|H_k) * p(H_k)} \end{aligned} \quad (6.5)$$

Persamaan di atas disebut sebagai *posterior probability* hypothesis  $H_i$  dari observasi terhadap evidence  $E_1, E_2, \dots, E_n$ .

Untuk memberikan ilustrasi bagaimana kepercayaan dipropagasikan dalam Bayes' rule, perhatikan contoh dalam Tabel 6.1. Tabel ini menjelaskan bahwa terdapat tiga mutually exclusive hypothesis, yaitu:  $H_1$ ,

Manager Lapindo melakukan kesalahan pengeboran,  $H_2$ , Manager Lapindo tidak mempunyai konsultan profesional, dan  $H_3$ , Manager Lapindo terkena getah akibat bencana alam. Juga terdapat dua evidence yang saling bebas, yaitu:  $E_1$ , Lumpur terus mengalir dan  $E_2$ , Patahan bor tertinggal dalam perut bumi, yang mendukung ketiga hypothesis.

Table 6.1: Contoh Kasus Propagasi Kepercayaan

	$i = 1$	$i = 2$	$i = 3$
	(kesalahan)	(tidak ada konsultan)	(bencana alam)
$p(H_i)$	0.4	0.6	0.1
$p(E_1 H_i)$	0.8	0.4	0.3
$p(E_2 H_i)$	0.9	0.6	0.0

Jika observasi dilakukan terhadap  $E_1$  (i.e., Lumpur terus mengalir), maka dengan menggunakan persamaan 6.5 kita dapat menghitung posterior probability dari masing-masing hypothesis sebagai berikut:

$$\begin{aligned}
 p(H_1|E_1) &= \frac{0.8 * 0.4}{0.8 * 0.4 + 0.4 * 0.6 + 0.3 * 0.1} = 0.54 \\
 p(H_2|E_1) &= \frac{0.4 * 0.6}{0.8 * 0.4 + 0.4 * 0.6 + 0.3 * 0.1} = 0.41 \\
 p(H_3|E_1) &= \frac{0.3 * 0.1}{0.8 * 0.4 + 0.4 * 0.6 + 0.3 * 0.1} = 0.05
 \end{aligned}$$

Perhatikan bahwa kepercayaan pada hypothesis  $H_2$  dan  $H_3$  menurun sedang tingkat kepercayaan pada hypothesis  $H_1$  naik setelah observasi terhadap  $E_1$ . Jika obeservasi sekarang juga dilakukan terhadap  $E_2$ , maka posterior probability dapat dihitung dengan:

$$\begin{aligned}
 p(H_1|E_1E_2) &= \frac{0.8 * 0.9 * 0.4}{0.8 * 0.9 * 0.4 + 0.4 * 0.6 * 0.6 + 0.3 * 0.0 * 0.1} = 0.67 \\
 p(H_2|E_1E_2) &= \frac{0.4 * 0.6 * 0.6}{0.8 * 0.9 * 0.4 + 0.4 * 0.6 * 0.6 + 0.3 * 0.0 * 0.1} = 0.33 \\
 p(H_3|E_1E_2) &= \frac{0.3 * 0.0 * 0.1}{0.8 * 0.9 * 0.4 + 0.4 * 0.6 * 0.6 + 0.3 * 0.0 * 0.1} = 0.0
 \end{aligned}$$

Pada contoh di atas hypothesis  $H_3$  bukan merupakan hypothesis yang valid, sedangkan hypothesis  $H_1$  sekarang dianggap lebih memungkinkan walaupun pada awalnya  $H_2$  berada diperingkat pertama.

### LATIHAN

Misalkan diketahui fakta sebagai berikut:

- (a) Probabilitas bahwa kita akan melihat buaya di sungai Jagir adalah 0.7.
- (b) Probabilitas bahwa banyak itik di sungai Jagir jika kita melihat buaya adalah 0.05.
- (c) Probabilitas bahwa banyak itik di sungai Jagir jika kita tidak melihat buaya di sungai adalah 0.2.

Berapa probabilitas kita melihat buaya jika terdapat beberapa itik di sungai Jagir<sup>1</sup>?

## 6.3 Certainty Factor

Note:

Pengetahuan di dalam sistem pakar yang direpresentasikan dengan menggunakan Certainty Facto (CF) diekspresikan dalam seperangkat aturan yang memiliki format:

IF EVIDENCE  
THEN HYPOTHESIS CF(RULE)

dimana Evidence adalah satu atau beberapa fakta yang diketahui untuk mendukung Hypothesis dan CF(RULE) adalah certainty factor untuk Hypothesis jika evidence diketahui.

<sup>1</sup> $p(H)=p(\text{Kita melihat buaya});p(E)=p(\text{Kita melihat itik di sungai Jagir});$  maka  $p(H|E)=0.368$ .



Seperti dalam pembahasan terdahulu, probabilitas dari suatu hypothesis terjadi jika diketahui/diberikan beberapa evidence disebut sebagai conditional probability dan disimbulkan sebagai  $p(H|E)$ . Jika  $p(H|E)$  lebih besar dari probabilitas sebelumnya, yaitu:  $p(H|E) > p(H)$ , maka berarti keyakinan pada hypothesis meningkat. Sebaliknya jika  $p(H|E)$  lebih kecil dari probabilitas sebelumnya, yaitu:  $p(H|E) < p(H)$ , maka keyakinan pada hypothesis akan menurun.

Ukuran yang menunjukkan peningkatan keyakinan pada suatu hypothesis berdasarkan evidence yang ada disebut sebagai *measure of belief* (MB). Sedangkan ukuran yang menunjukkan penurunan keyakinan pada suatu hypothesis berdasarkan evidence yang ada disebut sebagai *measure of disbelief* (MD).

Nilai dari MB dan MD dibatasi sedemikian sehingga:

$$0 \leq MB \leq 1$$

$$0 \leq MD \leq 1$$

Ukuran MB secara formal didefinisikan sebagai:

$$MB(H, E) = \begin{cases} 1 & \text{if } P(H) = 1 \\ \frac{\max[P(H|E), P(H)] - P(H)}{1 - P(H)} & \text{otherwise} \end{cases} \quad (6.6)$$

Sedangkan MD didefinisikan sebagai:

$$MD(H, E) = \begin{cases} 1 & \text{if } P(H) = 0 \\ \frac{P(H) - \min[P(H|E), P(H)]}{P(H)} & \text{otherwise.} \end{cases} \quad (6.7)$$

Karena dalam proses observasi kepercayaan dapat bertambah atau berkurang, maka diperlukan ukuran ketiga untuk mengkombinasikan MB dan MD, yaitu: *Certainty Factor*. Certainty Factor didefinisikan sebagai:

$$CF(H, E) = \frac{MB(H, E) - MD(H, E)}{1 - \min(MB(H, E), MD(H, E))} \quad (6.8)$$

Dimana nilai dari CF dibatasi oleh:

$$-1 \leq CF \leq 1$$

Nilai 1 berarti sangat benar, nilai 0 berarti tidak diketahui dan nilai -1 berarti sangat salah. Nilai CF negatif menunjuk pada derajat ketidakpercayaan sedang nilai CF positif menunjuk pada derajat kepercayaan.

### 6.3.1 Propagasi Keyakinan untuk Rule dengan Satu Premise

*Note:*

Yang dimaksud dengan propagasi keyakinan/kepercayaan adalah proses menentukan derajat kepercayaan pada kesimpulan pada kondisi dimana fakta/bukti/evidence yang ada tidak pasti (uncertain). Untuk rule dengan satu premise  $CF(H,E)$  didapatkan dengan rumusan:

$$CF(H, E) = CF(E) * CF(RULE) \quad (6.9)$$

### Propagasi Keyakinan untuk Rule dengan Beberapa Premise

Pada rule dengan beberapa premise terdapat dua macam penghubung yang biasa digunakan untuk menghubungkan premise-premise tersebut: konjungsi dan disjungsi. *Note:*

#### Rule dengan Konjungsi

Pada rule dengan konjungsi, pendekatan yang digunakan adalah sebagai berikut:

$$\begin{aligned} & \text{IF } E_1 \text{ AND } E_2 \text{ AND } \dots \text{ THEN } H \quad CF(RULE) \\ & CF(H, E_1 \text{ AND } E_2 \text{ AND } \dots) = \min\{CF(E_i)\} * CF(RULE) \quad (6.10) \end{aligned}$$

Fungsi 'min' akan mengembalikan nilai paling kecil dari 1 set evidence yang ada.

Perhatikan contoh dibawah ini:

IF        Suhu udara rata-rata turun  
 AND     Hembusan angin semakin kencang  
 THEN    Musim hujan akan segera datang. (CF=0.8)

Asumsikan bahwa derajat kepercayaan kita pada premise pertama adalah:

$$CF(\text{Suhu udara rata-rata turun}) = 1.0$$

dan derajat kepercayaan pada premise kedua:

$$CF(\text{Hembusan angin semakin kencang}) = 0.7$$

Maka derajat kepercayaan bahwa 'Musim hujan akan datang' dapat dihitung:

$$\begin{aligned} &CF(\text{Musim hujan akan datang jika} \\ &\text{suhu udara rata-rata turun AND} \\ &\text{hembusan angin semakin kencang}) = \min\{1.0, 0.7\} * 0.8 = 0.56 \end{aligned}$$

Berarti bahwa: Musim hujan *mungkin* akan datang.

#### Rule dengan disjungsi

Pada rule dengan disjungsi, pendekatan yang digunakan adalah sebagai berikut:

$$\begin{aligned} &\text{IF } E_1 \text{ OR } E_2 \text{ OR } \dots \text{ THEN } H \quad CF(\text{RULE}) \\ &CF(H, E_1 \text{ OR } E_2 \text{ OR } \dots) = \max\{CF(E_i)\} * CF(\text{RULE}) \quad (6.11) \end{aligned}$$

Fungsi 'max' akan mengembalikan nilai paling besar dari 1 set evidence yang ada.

Contoh:

IF        Suhu udara rata-rata turun  
 OR        Hembusan angin semakin kencang  
 THEN    Musim hujan akan datang. (CF=0.9)

Maka derajat kepercayaan bahwa 'Musim hujan akan datang' adalah:

CF(Musim hujan akan datang *jika*  
 suhu udara rata-rata turun *OR*  
 hembusan angin semakin kencang) =  $\max\{1.0, 0.7\} * 0.9 = 0.9$

Berarti bahwa: Musim hujan *hampir pasti* akan datang.

### LATIHAN

Bagaimana bentuk certainty factor dari hypothesis untuk rule seperti ditunjukkan di bawah ini:

IF         $E_1$   
 AND      $E_2$   
 OR        $E_3$   
 AND      $E_4$   
 THEN    H CF(RULE).

### 6.3.2 Rule dengan konklusi yang sama

Dalam proses eksekusi rule, mungkin sekali terjadi bahwa beberapa rule dapat menghasilkan hypothesis atau kesimpulan yang sama. Karena itu harus ada mekanisme untuk mengkombinasikan beberapa hypothesis tersebut untuk menjadi satu buah hypothesis saja. Persamaan untuk

menggabungkan dua buah CF adalah sebagai berikut:

$$CF_{\text{kombinasi}}(CF_{\text{lama}}, CF_{\text{baru}}) = \begin{cases} CF_{\text{lama}} + CF_{\text{baru}}(1 - CF_{\text{lama}}) & \text{both} > 0 \\ CF_{\text{lama}} + CF_{\text{baru}}(1 + CF_{\text{lama}}) & \text{both} < 0 \\ \frac{CF_{\text{lama}} + CF_{\text{baru}}}{1 - \min(|CF_{\text{lama}}|, |CF_{\text{baru}}|)} & \text{one} < 0 \end{cases} \quad (6.12)$$

Untuk menjelaskan bagaimana keyakinan dipropagasikan dalam Certainty Factor, maka dalam bagian ini akan diberikan dua contoh kasus yang diselesaikan dengan model Certainty Factor.

#### Contoh 1:

Contoh pertama adalah berkaitan dengan proses keputusan di dalam sebuah pengadilan dimana seseorang telah dituduh terlibat dalam pembunuhan tingkat pertama (hypothesis). Contoh ini diambil dari Gonzales (1993). Berdasarkan fakta-fakta yang ada (evidence) hakim harus memutuskan apakah orang tersebut bersalah. Pada awal proses peradilan, hakim harus menjunjung tinggi asas praduga tak bersalah, karena itu pada certainty factor dari 'bersalah' bernilai 0 ( $CF=0$ ). Perhatikan rule-rule dibawah ini:

- R1 IF Sidik jari tertuduh ada pada senjata pembunuh,  
THEN Tertuduh bersalah. ( $CF = 0.75$ )
- R2 IF Tertuduh memiliki motif,  
THEN Tertuduh bersalah melakukan kejahatan. ( $CF = 0.6$ )
- R3 IF Tertuduh memiliki alibi,  
THEN Tertuduh tidak bersalah. ( $CF = -0.8$ )

Dalam proses peradilan diketahui fakta-fakta sebagai berikut:

- Sidik jari tertuduh ada pada senjata pembunuh ( $CF = 0.9$ ).
- Tertuduh memiliki motif ( $CF=0.5$ ).
- Tertuduh memiliki alibi ( $CF=0.95$ ).

Penyelesaian untuk kasus di atas adalah sebagai berikut:

STEP 0

Dengan menjunjung asas praduga tak bersalah, pada tahap awal hakim akan mengasumsikan bahwa "tertuduh bersalah" memiliki  $CF=0$ , seperti ditunjukkan dalam Gambar 6.1.




Figure 6.1: Tertuduh bersalah,  $CF=0$

STEP 1

Diketahui bahwa premise dari R1 memiliki evidence dengan nilai  $CF=0.9$ . Maka hasil propagasi keyakinan yang memberi pengaruh pada bagian hypothesis adalah:

$$\begin{aligned} CF_{\text{kombinasi1}} &= CF_{R1} * CF_{\text{evid1}} \\ &= 0.75 * 0.9 \\ &= 0.675 \end{aligned} \tag{6.13}$$

Karena pada saat awal kita asumsikan bahwa nilai 'bersalah' adalah 0, maka  $CF_{\text{revisi}}$  dapat dicari dengan:

$$\begin{aligned} CF_{\text{revisi}} &= CF_{\text{lama}} + CF_{\text{baru}} * (1 - CF_{\text{lama}}) \\ &= 0.0 + 0.675 * (1 - 0) \\ &= 0.675 \end{aligned} \tag{6.14}$$

Hasil propagasi kepercayaan R1 menyebabkan nilai CF sekarang berubah menjadi 0.675. Ditunjukkan dalam Gambar 6.2. Yang berarti: dengan adanya R1 meningkatkan kepercayaan bahwa tertuduh bersalah. Tetapi hakim tidak akan langsung mengetokkan palu tanda bersalah sebelum bukti-bukti yang lain diuji.

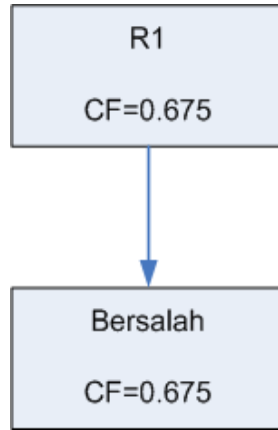


Figure 6.2: Tertuduh bersalah, CF=0.675

### STEP 2

Diketahui bahwa premise dari R2 memiliki evidence dengan nilai CF=0.5. Maka hasil propagasi keyakinan yang memberi pengaruh pada bagian hypothesis dari R2 adalah:

$$\begin{aligned}
 CF_{\text{kombinasi2}} &= CF_{R2} * CF_{\text{evid2}} \\
 &= 0.6 * 0.5 \\
 &= 0.30
 \end{aligned} \tag{6.15}$$

Pada step 1 kita dapatkan dengan CF=0.675, maka selanjutnya tingkat keyakinan dipropagasikan dengan adanya evidence kedua menjadi:

$$\begin{aligned}
 CF_{\text{revisi}} &= CF_{\text{lama}} + CF_{\text{baru}} * (1 - CF_{\text{lama}}) \\
 &= 0.675 + 0.3 * (1 - 0.675) \\
 &= 0.7725
 \end{aligned} \tag{6.16}$$

Hasil kombinasi antara R1 dan R2 ternyata semakin meningkatkan kepercayaan bahwa tertuduh memang bersalah. Perhatikan Gambar 6.3.

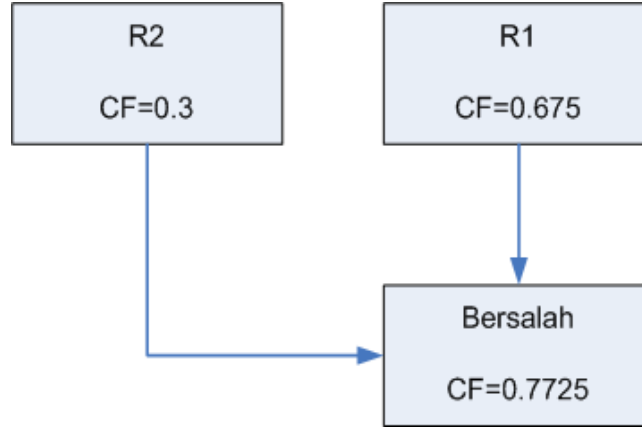


Figure 6.3: Tertuduh bersalah, CF=0.7725

### STEP 3

Diketahui bahwa premise dari R3 memiliki evidence dengan nilai CF=0.95. Maka hasil propagasi keyakinan yang memberi pengaruh pada bagian hypothesis dari R3 adalah:

$$\begin{aligned}
 CF_{\text{kombinasi3}} &= CF_{R3} * CF_{\text{evid3}} \\
 &= 0.95 * (-0.80) \\
 &= -0.76
 \end{aligned} \tag{6.17}$$

Hasil kombinasi terakhir memberikan nilai:

$$\begin{aligned}
 CF_{\text{revisi}} &= \frac{CF_{\text{lama}} + CF_{\text{baru}}}{1 - \min(|CF_{\text{lama}}|, |CF_{\text{baru}}|)} \\
 &= \frac{0.7725 - 0.76}{1 - 0.76} \\
 &= 0.052
 \end{aligned} \tag{6.18}$$

Karena itu hasil akhir dari proses peradilan: hakim tidak dapat memutuskan bahwa tertuduh bersalah. Bukti lain dibutuhkan untuk menentukan tertuduh bersalah atau tidak. Perhatikan Gambar 6.4.



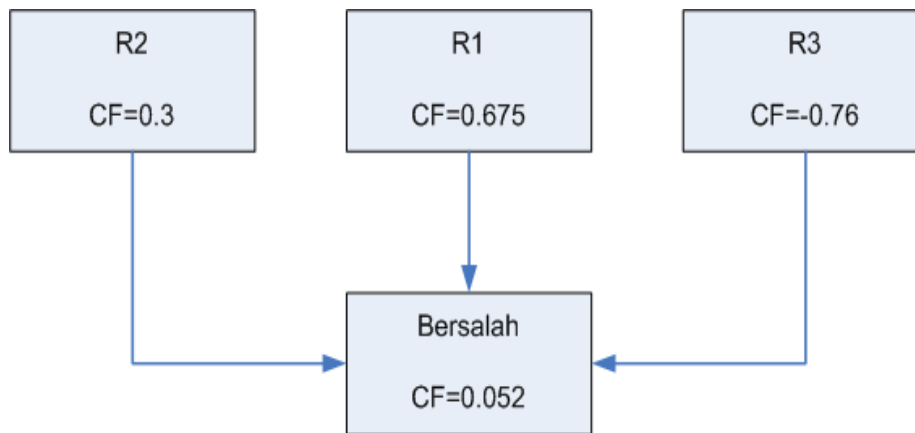


Figure 6.4: Tertuduh bersalah,  $CF=0.052$

### Contoh 2:

Problem berikutnya adalah menentukan apakah saya seharusnya pergi bermain bola atau tidak. Kita asumsikan bahwa hypothesis adalah: "Saya seharusnya tidak pergi bermain bola" dan penyelesaian dilakukan dengan metoda backward reasoning. Rule-rule yang digunakan adalah sebagai berikut:

R1	IF	Cuaca kelihatan mendung,	E1
	OR	Saya dalam suasana hati tidak enak,	E2
	THEN	Saya seharusnya tidak pergi bermain bola. ( $CF = 0.9$ )	H1
R2	IF	Saya percaya akan hujan,	E3
	THEN	Cuaca kelihatan mendung. ( $CF = 0.8$ )	E1
R3	IF	Saya percaya akan hujan,	E3
	AND	Ramalan cuaca mengatakan akan hujan,	E4
	THEN	Saya dalam suasana hati tidak enak. ( $CF = 0.9$ )	E2
R4	IF	Ramalan cuaca mengatakan akan hujan,	E4
	THEN	Cuaca kelihatan mendung. ( $CF = 0.7$ )	E1
R5	IF	Cuaca kelihatan mendung,	E1
	THEN	Saya dalam suasana hati tidak enak. ( $CF = 0.95$ )	E2

Dan diketahui fakta-fakta sebagai berikut:

- Saya percaya akan hujan (CF=0.95).
- Ramalan cuaca mengatakan akan hujan (CF=0.85).

Penyelesaian untuk kasus di atas adalah sebagai berikut:

STEP 1

Perhatikan bahwa premise pertama pada R1 (yang disimbolkan dengan E1) merupakan konklusi dari R2 dan R4. Sistem akan mengerjakan R2 terlebih dahulu karena R2 memiliki nilai CF lebih besar daripada R4. Maka:

$$\begin{aligned} \text{CF}(\text{E1}, \text{E3}) &= \text{CF}_{\text{R2}} * \text{CF}_{\text{E3}} \\ &= 0.8 * 0.95 \\ &= 0.76 \end{aligned} \tag{6.19}$$

Setelah itu kita kerjakan R4 sehingga:

$$\begin{aligned} \text{CF}(\text{E1}, \text{E4}) &= \text{CF}_{\text{R4}} * \text{CF}_{\text{E4}} \\ &= 0.7 * 0.85 \\ &= 0.60 \end{aligned} \tag{6.20}$$

Sekarang kita memiliki 2 buah fakta baru yang memberikan konfirmasi tentang E1 (Cuaca kelihatan mendung), kombinasi dari kedua buah fakta tersebut adalah:

$$\begin{aligned} \text{CF}(\text{E1}) &= \text{CF}(\text{E1}, \text{E3}) + \text{CF}(\text{E1}, \text{E4}) * (1 - \text{CF}(\text{E1}, \text{E3})) \\ &= 0.76 + 0.6 * (1 - 0.76) \\ &= 0.9 \end{aligned} \tag{6.21}$$

STEP 2

Perhatikan bahwa premise kedua pada R1 (yang disimbolkan dengan E2) merupakan konklusi dari R3 dan R5. Sistem akan mengerjakan R5

terlebih dahulu karena R5 memiliki nilai CF lebih besar daripada R3.

Maka:

$$\begin{aligned} \text{CF}(\text{E2}, \text{E1}) &= \text{CF}_{\text{R5}} * \text{CF}_{\text{E1}} \\ &= 0.95 * 0.9 \\ &= 0.86 \end{aligned} \tag{6.22}$$

Selanjutnya sistem akan mengerjakan R3 sehingga:

$$\begin{aligned} \text{CF}(\text{E1}, \text{E3 AND E4}) &= \min\{\text{CF}_{\text{E3}}, \text{CF}_{\text{E4}}\} * \text{CF}_{\text{R3}} \\ &= \min\{0.85, 0.85\} * 0.9 \\ &= 0.77 \end{aligned} \tag{6.23}$$

Sekarang kita memiliki 2 buah fakta baru yang memberikan konfirmasi tentang E2 (Saya dalam suasana hati tidak enak), kombinasi dari kedua buah fakta tersebut adalah:

$$\begin{aligned} \text{CF}(\text{E2}) &= \text{CF}(\text{E2}, \text{E1}) + \text{CF}(\text{E2}, \text{E3 AND E4}) * (1 - \text{CF}(\text{E2}, \text{E1})) \\ &= 0.86 + 0.77 * (1 - 0.86) \\ &= 0.97 \end{aligned} \tag{6.24}$$

### STEP 3

Kembali ke R1, maka nilai CF untuk H1 jika diberikan E1 OR E2 adalah:

$$\begin{aligned} \text{CF}(\text{H1}, \text{E1 OR E2}) &= \max\{\text{CF}_{\text{E1}}, \text{CF}_{\text{E2}}\} * \text{CF}_{\text{R1}} \\ &= \max\{0.9, 0.97\} * 0.9 \\ &= 0.87 \end{aligned} \tag{6.25}$$

Yang berarti bahwa: Saya seharusnya tidak pergi bermain bola.

## 6.4 SOAL LATIHAN:

Dengan menggunakan seperangkat rule dan fakta dibawah ini, hitunglah kemungkinan pencuri mobil dari Tim. Mike atau John yang layak di-

tuduh sebagai pencuri?

Diketahui fakta-fakta sebagai berikut:

- Mobil dari Mike mogok (berarti dia membutuhkan transportasi) (CF=1.0).
- Mobil dari John tidak mogok (berarti dia tidak membutuhkan transportasi) (CF=1.0).
- Sidik jari dari Mike ada pada mobil (CF=1.0).
- Sidik jari dari John tidak ada pada mobil (CF=1.0).
- Sidik jari dari Mike tidak ada pada kunci (CF=1.0).
- Sidik jari dari John ada pada kunci (CF=1.0).
- Kunci mobil dari Tim tertinggal dalam mobil (CF=1.0).
- Mike tidak menyukai Tim (CF=0.6).
- John menyukai Tim (CF=0.8).
- Mike sedang melihat televisi ketika pencurian terjadi (berarti dia memiliki alibi) (CF=0.85).
- John sedang tidur ketika pencurian terjadi (berarti dia memiliki alibi) (CF=0.2)

- R1 IF        Tertuduh memiliki motif,  
     AND     Tertuduh memiliki kesempatan  
     THEN    Tertuduh bersalah karena melakukan kejahatan. (CF = 0.6)
- R2 IF        Tertuduh memiliki alibi,  
     THEN    Tertuduh bersalah. (CF = -0.8)
- R3 IF        Sidik jari dari tertuduh ditemukan pada mobil,  
     THEN    Tertuduh bersalah. (CF = 0.4)
- R4 IF        Kunci tertinggal di dalam mobil,  
     THEN    Tertuduh memiliki kesempatan. (CF = 0.9)
- R5 IF        Tertuduh tidak menyukai Tim,  
     THEN    Tertuduh memiliki motif. (CF = 0.5)
- R6 IF        Tertuduh membutuhkan transportasi,  
     THEN    Tertuduh memiliki motif. (CF = 0.9)
- R7 IF        Sidik jari dari tertuduh ditemukan pada kunci,  
     THEN    Tertuduh bersalah. (CF = 0.7)